LAB2 Частина 3. Оброблення даних про успішність

Виконавець: **Тижук Дмитро Іванович**, група **К-26**
Викладач: **Лякшо А. В.**

Нам знадобиться бібліотека `pandas`.
Бібліотека є сторонньою, отже потребує встановлення. Краще у віртуальне оточення.
Мала бути встановлена, якщо ні (клітина з імпортуванням виконується з помилкою), то треба встановити. Можна прямо з Jupyter. Тільки не під час пари.

Наступну клітину можна розкоментовувати та виконувати тільки, якщо в якості ядра (kernel) вибране віртуальне оточення!

In [1]:
```
#!pip install pandas
```

Якщо встановлювати не в оточення, то хоча б тільки для користувача (з ключем --user).

In [2]:
```
#!pip3.14 install pandas --user    # Linux
```

In [3]:
```
#!py -3.14 -m pip install pandas --user    # Windows
```

In [4]:
```
from pathlib import Path
import pandas as pd

print(f"pandas {pd.__version__}")
```

```
pandas 3.0.1
```

Постановка задачі

У файлі `data_new.csv` знаходяться дані з поточними результатами студентів за ЛР, що складається з двох частин. Відомо, що файли записаний у форматі csv з кодуванням utf-8, може містити білі рядки та містить заголовок. Також відомо, що інформація про жодного студента не записана на кількох рядках одночасно.

Завдання: З використанням виключно засобів бібліотеки `pandas`

1. Завантажити наявну у файлах інформацію в об'єкт `DataFrame`.
   Заголовками стовпчиків мають бути: `group`, `name`, `var`, `part1`, `part2`.
2. Знайти про скількох студентів наявна інформація у файлі.
3. Знайти студентів, хто здав обидві частини. Скільки таких студентів?
   Цікавить тільки група, ПІБ, номер варіанту, загальна кількість балів. Тут і далі: здали = отримали бали, можливо нулеві.

4. Знайти тих студентів, хто не здав жодної частини. Скільки таких студентів? Цікавить тільки група, ПІБ, номер варіанту.
5. Знайти тих студентів, хто здав першу частину. Цікавить тільки група, ПІБ, номер варіанту, бали за першу частину.
6. Знайти тих студентів групи К14, що здали хоч одну частину лабораторної. Цікавить уся наявна інформація.
7. Для кожної групи знайти кількість студентів та кількість студентів, що щось здали.

Крок 1 Завантажити наявну у файлах інформацію в об'єкт `DataFrame`.

Заголовками стовпчиків мають бути: `group`, `name`, `var`, `part1`, `part2`.

Задаємо шлях до файлу `data_new.csv`.

In [5]:
```
path = Path("./data_new.csv")
```

Завантажимо дані за допомогою функції `pd.read_csv` (документація тут).

Зверніть увагу на те, що:

1. файл записано в кодуванні `utf-8`
2. перший рядок файлу містить заголовки, проте під час завантаження слід підставити власні заголовки group, name, var, part1, part2
3. значення в деяких стовпчиках можуть бути відсутні

▶ Підказки.

▶ Ще більше підказок

In [6]:
```
data = pd.read_csv(
    path,
    encoding="utf-8",
    header=0,
    names=["group", "name", "var", "part1", "part2"],
    sep=",",
    dtype={"part1": "Int64", "part2": "Int64"}
)
data.head()
```

Out[6]:

	group	name	var	part1	part2
0	К10	Прізвище3 Ім'я3	1	<NA>	<NA>
1	К10	Прізвище9 Ім'я9	2	<NA>	<NA>
2	К10	Прізвище16 Ім'я16	3	<NA>	<NA>
3	К10	Прізвище18 Ім'я18	4	<NA>	<NA>
4	К10	Прізвище25 Ім'я25	5	<NA>	9

In [7]:
```
data.tail()
```

Out[7]:

	group	name	var	part1	part2
126	К14	Прізвище112 Ім'я112	132	<NA>	<NA>
127	К14	Прізвище117 Ім'я117	133	<NA>	<NA>
128	К14	Прізвище120 Ім'я120	134	<NA>	<NA>
129	К14	Прізвище126 Ім'я126	135	<NA>	<NA>
130	К14	Прізвище127 Ім'я127	136	<NA>	<NA>

Подивимось інформацію про завантажені дані. Документація на метод `info`.

In [8]:
```
data.info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 131 entries, 0 to 130
Data columns (total 5 columns):
 #   Column  Non-Null Count  Dtype
---  ------  --------------  -----
 0   group   131 non-null    str
 1   name    131 non-null    str
 2   var     131 non-null    int64
 3   part1   13 non-null     Int64
 4   part2   13 non-null     Int64
dtypes: Int64(2), int64(1), str(2)
memory usage: 5.5 KB
```

Крок 2 Знайти про скількох студентів наявна інформація у файлах.

▶ Підказка.

In [9]:
```
data["name"].size
```

Out[9]: 131

Крок 3 Знайти студентів, хто здав обидві частини. Скільки таких студентів?

Цікавить тільки група, ПІБ, номер варіанту, загальна кількість балів.
Тут і далі: здали = отримали бали, можливо нулеві.

▶ Підказка.

3.1 Для рядків таблиці визначити, чи правда що в рядку обидва поля `part1`, `part2` заповнені.
Підказка. Метод `notna` обчислює ознаку наявності значення поля.

▶ Ще підказки

In [10]:
```
task3_mask = data["part1"].notna() & data["part2"].notna()
task3_mask
```

Out[10]:
```
0      False
1      False
2      False
3      False
4      False
       ...
126    False
127    False
128    False
129    False
130    False
Length: 131, dtype: bool
```

3.2 Щоб знайти шукану кількість студентів достатньо знайти кількість рядків, для яких обчислена ознака істинна.

▶ Підказка

In [11]:
```
task3_mask.sum()
```

Out[11]:
```
np.int64(12)
```

3.3 Щоб знайти шуканих студентів, слід профільтрувати загальну таблицю за обчисленою ознакою.
Копію (використати метод `copy`) отриманого результату зберегти в змінну `task3`.

Примітка. Надалі до отриманої вибірки будемо додавати стовпчики, тому важливо, щоб вибірка не використовувала дані спільно з первинною таблицею.

In [12]:
```
task3 = data[task3_mask].copy()
task3.head()
```

Out[12]:

	group	name	var	part1	part2
32	K11	Прізвище0 Ім'я0	38	6	9
38	K11	Прізвище51 Ім'я51	44	6	9
46	K11	Прізвище84 Ім'я84	52	6	9
58	K12	Прізвище12 Ім'я12	64	6	9
64	K12	Прізвище40 Ім'я40	70	6	9

3.4 До отриманої таблиці додати суму балів під іменем `total`.

In [13]:
```
task3["total"] = task3["part1"] + task3["part2"]
task3.head()
```

Out[13]:

	group	name	var	part1	part2	total
32	K11	Прізвище0 Ім'я0	38	6	9	15
38	K11	Прізвище51 Ім'я51	44	6	9	15
46	K11	Прізвище84 Ім'я84	52	6	9	15
58	K12	Прізвище12 Ім'я12	64	6	9	15
64	K12	Прізвище40 Ім'я40	70	6	9	15

3.5 З отриманої таблиці вибрати стовпчики `group`, `name`, `var`, `total`.

In [14]:
```
task3[["group", "name", "var", "total"]]
```

Out[14]:

	group	name	var	total
32	K11	Прізвище0 Ім'я0	38	15
38	K11	Прізвище51 Ім'я51	44	15
46	K11	Прізвище84 Ім'я84	52	15
58	K12	Прізвище12 Ім'я12	64	15
64	K12	Прізвище40 Ім'я40	70	15
88	K13	Прізвище4 Ім'я4	94	15
89	K13	Прізвище6 Ім'я6	95	15
92	K13	Прізвище24 Ім'я24	98	15
95	K13	Прізвище33 Ім'я33	101	15
103	K13	Прізвище97 Ім'я97	109	15
106	K13	Прізвище107 Ім'я107	112	15
119	K14	Прізвище62 Ім'я62	125	15

Крок 4 Знайти тих студентів, хто не здав жодної частини. Скільки таких студентів?

Цікавить тільки група, ПІБ, номер варіанту.

▶ Підказки

In [15]:
```
task4_mask = data["part1"].isna() & data["part2"].isna()
data[["group", "name", "var"]][task4_mask]
```

Out[15]:

	group	name	var
0	K10	Прізвище3 Ім'я3	1
1	K10	Прізвище9 Ім'я9	2
2	K10	Прізвище16 Ім'я16	3
3	K10	Прізвище18 Ім'я18	4
5	K10	Прізвище30 Ім'я30	6
...	...	...	...
126	K14	Прізвище112 Ім'я112	132
127	K14	Прізвище117 Ім'я117	133
128	K14	Прізвище120 Ім'я120	134
129	K14	Прізвище126 Ім'я126	135
130	K14	Прізвище127 Ім'я127	136

117 rows × 3 columns

In [16]:
```
task4_mask.sum()
```

Out[16]:
```
np.int64(117)
```

Крок 5 Знайти тих студентів, хто здав першу частину.

Цікавить тільки група, ПІБ, номер варіанту, бали за першу частину.

▶ Підказки

In [17]:
```
task5_mask = data["part1"].notna()
data[["group", "name", "var", "part1"]][task5_mask]
```

Out[17]:

	group	name	var	part1
32	K11	Прізвище0 Ім'я0	38	6
38	K11	Прізвище51 Ім'я51	44	6
46	K11	Прізвище84 Ім'я84	52	6
58	K12	Прізвище12 Ім'я12	64	6
64	K12	Прізвище40 Ім'я40	70	6
88	K13	Прізвище4 Ім'я4	94	6
89	K13	Прізвище6 Ім'я6	95	6
92	K13	Прізвище24 Ім'я24	98	6
95	K13	Прізвище33 Ім'я33	101	6
103	K13	Прізвище97 Ім'я97	109	6
106	K13	Прізвище107 Ім'я107	112	6
110	K14	Прізвище5 Ім'я5	116	6
119	K14	Прізвище62 Ім'я62	125	6

Крок 6 Знайти студентів групи K14, що здали хоч одну частину лабораторної. Цікавить уся наявна інформація.

Підказки

- Знайти рядки таблиці, що стосуються студентів групи K14.
- Знайти рядки таблиці, в яких хоча б один зі стовпчиків `part1`, `part2` заповнений.
- Скомбінувати попередні умови: відповідна вибірка буде шуканою.

6.1 Знайти рядки таблиці, що стосуються студентів групи K14.

▶ Підказка

In [18]:
```
task6_part1_mask = data["group"] == "K14"
data[task6_part1_mask]
```

Out[18]:

	group	name	var	part1	part2
110	К14	Прізвище5 Ім'я5	116	6	<NA>
111	К14	Прізвище7 Ім'я7	117	<NA>	<NA>
112	К14	Прізвище10 Ім'я10	118	<NA>	<NA>
113	К14	Прізвище15 Ім'я15	119	<NA>	<NA>
114	К14	Прізвище21 Ім'я21	120	<NA>	<NA>
115	К14	Прізвище34 Ім'я34	121	<NA>	<NA>
116	К14	Прізвище1 Ім'я1	122	<NA>	<NA>
117	К14	Прізвище47 Ім'я47	123	<NA>	<NA>
118	К14	Прізвище56 Ім'я56	124	<NA>	<NA>
119	К14	Прізвище62 Ім'я62	125	6	9
120	К14	Прізвище67 Ім'я67	126	<NA>	<NA>
121	К14	Прізвище77 Ім'я77	127	<NA>	<NA>
122	К14	Прізвище82 Ім'я82	128	<NA>	<NA>
123	К14	Прізвище86 Ім'я86	129	<NA>	<NA>
124	К14	Прізвище98 Ім'я98	130	<NA>	<NA>
125	К14	Прізвище101 Ім'я101	131	<NA>	<NA>
126	К14	Прізвище112 Ім'я112	132	<NA>	<NA>
127	К14	Прізвище117 Ім'я117	133	<NA>	<NA>
128	К14	Прізвище120 Ім'я120	134	<NA>	<NA>
129	К14	Прізвище126 Ім'я126	135	<NA>	<NA>
130	К14	Прізвище127 Ім'я127	136	<NA>	<NA>

6.2 Знайти рядки таблиці, в яких хоча б один зі стовпчиків `part1`, `part2` заповнений.

▶ Підказки

In [19]:
```
task6_part2_mask = data["part1"].notna() | data["part2"].notna()
task6_part2_mask
```

Out[19]:
```
0      False
1      False
2      False
3      False
4       True
       ...
126    False
127    False
128    False
129    False
130    False
Length: 131, dtype: bool
```

6.3 Скомбінувати попередні умови: відповідна вибірка буде шуканою.

In [20]:
```
data[task6_part1_mask & task6_part2_mask]
```

Out[20]:

	group	name	var	part1	part2
110	K14	Прізвище5 Ім'я5	116	6	<NA>
119	K14	Прізвище62 Ім'я62	125	6	9

Крок 7 Для кожної групи знайти кількість студентів та кількість студентів, що щось здали.

7.1 Обчислити для кожного студента ознаку, чи здав він хоча б одну з частин, та додати відповідний стовпчик до таблиці. Назвати доданий стовпчик `done`.

In [21]:
```
data["done"] = task6_part2_mask
data.head()
```

Out[21]:

	group	name	var	part1	part2	done
0	K10	Прізвище3 Ім'я3	1	<NA>	<NA>	False
1	K10	Прізвище9 Ім'я9	2	<NA>	<NA>	False
2	K10	Прізвище16 Ім'я16	3	<NA>	<NA>	False
3	K10	Прізвище18 Ім'я18	4	<NA>	<NA>	False
4	K10	Прізвище25 Ім'я25	5	<NA>	9	True

7.2 З використанням методу `groupby` виконати групування по групах.

Далі за допомогою методу `agg` для кожної групи для стовпчика `done` обчислити кількість (`count`) та суму (`sum`) значень. Це буде кількість студентів групи та кількість студентів групи, що щось здали.
Результат присвоїти змінній `res`

In [22]:
```
res = data.groupby(by="group").agg({"done": ["count", "sum"]})
res
```

Out[22]:

	done	
	count	**sum**
group		
K10	26	1
K11	31	3
K12	31	2
K13	22	6
K14	21	2

Перейменуємо заголовки колонок.

In [23]:
```
res.columns = ("number", "works")
res
```

Out[23]:

group	number	works
K10	26	1
K11	31	3
K12	31	2
K13	22	6
K14	21	2

Розрахувати кількість студентів, що нічого не здали. Результат обчислення записати в стовпчик `lazy`.

In [24]:
```
res["lazy"] = res["number"] - res["works"]
res
```

Out[24]:

group	number	works	lazy
K10	26	1	25
K11	31	3	28
K12	31	2	29
K13	22	6	16
K14	21	2	19

Частину 3 зроблено!